

SOAL LATIHAN PRAKTIKUM DATA SCIENCE

CLUSTERING: K-MEANS DAN HIERARCHICAL CLUSTERING

Studi Kasus: Segmentasi Negara untuk Prioritas Bantuan Internasional

Sebuah organisasi non-profit internasional (NGO) yang berfokus pada bantuan kemanusiaan ingin menentukan negara-negara yang paling membutuhkan bantuan dana secara tepat sasaran. NGO memiliki data indikator sosial-ekonomi dan kesehatan dari berbagai negara, seperti angka kematian anak (child_mort), pendapatan per kapita (income), harapan hidup (life_expec), dan GDP per kapita (gdpp). NGO ingin mengelompokkan negara-negara berdasarkan kondisi sosial-ekonominya untuk memahami karakteristik setiap kelompok negara sebelum menentukan prioritas penyaluran bantuan.

Dataset

Country-data.csv

Sumber: Unsupervised Learning on Country Data – Kaggle

(<https://www.kaggle.com/datasets/rohan0301/unsupervised-learning-on-country-data>)

Tujuan Praktikum

Menerapkan K-Means dan Hierarchical Clustering pada dataset yang sama, mengevaluasi hasil clustering, serta membandingkan karakteristik cluster yang dihasilkan oleh kedua metode.

Ketentuan Umum

- Gunakan dataset Country-data.csv yang telah disediakan.
- Lakukan preprocessing yang diperlukan, meliputi pemeriksaan missing value, data duplikat/redundan, feature selection, dan scaling.
- Gunakan fitur numerik yang menggambarkan kondisi sosial-ekonomi dan kesehatan tiap negara (child_mort, exports, health, imports, income, inflation, life_expec, total_fer, gdpp). Jangan menggunakan country (nama negara) sebagai fitur clustering.
- Gunakan hasil preprocessing dan standardisasi yang sama untuk K-Means dan Hierarchical Clustering agar hasil kedua metode dapat dibandingkan secara adil.
- Kerjakan seluruh analisis secara mandiri menggunakan Python/Jupyter Notebook atau Google Colab.

A. K-MEANS CLUSTERING

Lakukan segmentasi menggunakan algoritma K-Means. Tentukan jumlah cluster berdasarkan hasil analisis, bukan dengan menetapkan jumlah cluster secara sembarang.

Lakukan EDA sederhana untuk memahami struktur, tipe data, distribusi, dan permasalahan pada dataset.

Lakukan preprocessing dan feature selection sesuai kebutuhan.

Lakukan standardisasi terhadap fitur yang digunakan.

Gunakan Elbow Method untuk membantu menentukan jumlah cluster.

Terapkan K-Means menggunakan jumlah cluster yang dipilih.

Evaluasi hasil clustering menggunakan Silhouette Score.

Buat visualisasi hasil clustering yang sesuai.

Buat profil setiap cluster berdasarkan nilai rata-rata fitur dan jelaskan karakteristiknya.

Pertanyaan Analisis K-Means

- Berdasarkan Elbow Method dan Silhouette Score, berapa jumlah cluster yang digunakan? Jelaskan dasar pemilihannya.
- Bagaimana karakteristik utama dari setiap cluster berdasarkan kondisi sosial-ekonomi negara? Kelompok mana yang menurutmu paling membutuhkan bantuan?

B. HIERARCHICAL CLUSTERING

Gunakan dataset dan hasil preprocessing yang sama seperti pada bagian K-Means. Selanjutnya, lakukan segmentasi menggunakan Agglomerative Hierarchical Clustering untuk melihat bagaimana struktur cluster yang dihasilkan dibandingkan dengan K-Means.

Terapkan Agglomerative Clustering menggunakan linkage Ward, Average, Complete, dan Single.

Hitung Silhouette Score untuk masing-masing linkage dan bandingkan hasilnya.

Buat dendrogram menggunakan metode linkage Ward.

Tentukan jumlah cluster yang wajar berdasarkan dendrogram.

Buat heatmap fitur yang telah distandarisasi dan diurutkan berdasarkan label cluster.

Buat profil dan jelaskan karakteristik cluster yang terbentuk.

Pertanyaan Analisis Hierarchical

- Linkage mana yang menghasilkan Silhouette Score paling tinggi? Jelaskan apa yang dapat ditunjukkan oleh hasil tersebut.
- Berdasarkan dendrogram Ward, berapa jumlah cluster yang menurutmu paling wajar? Jelaskan dasar pilihannya.

C. PERBANDINGAN HASIL

Bandungkan hasil K-Means dan Hierarchical Clustering karena kedua metode diterapkan pada dataset dan hasil preprocessing yang sama.

- Apa perbedaan utama hasil K-Means dan Hierarchical Clustering pada dataset yang sama? Jelaskan berdasarkan jumlah cluster, pembagian data, atau karakteristik cluster yang terbentuk.